

Pipeline Machine Learning untuk Prediksi Permeabilitas Membran Lipid Bilayer Berdasarkan Deskriptor Fisikokimia Molekuler

Andri Nurdianto - 13523145; Aulia Azka Azzahra - 18223131;
Muhammad Rafly Fauzan - 18223132; Sonya Putri Fadilah - 18223138

IF3211 - Komputasi Domain Spesifik
Program Studi Sistem dan Teknologi Informasi, Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung, Jalan Ganesha 10 Bandung

Membran plasma memiliki sifat permeabilitas selektif yang memungkinkan sel mengatur perpindahan molekul antara lingkungan internal dan eksternal. Sifat ini dipengaruhi oleh karakteristik fisikokimia molekul, seperti ukuran, lipofilisitas, polaritas, jumlah donor dan akseptor ikatan hidrogen, fleksibilitas, serta muatan. Penelitian ini membangun pipeline machine learning untuk memprediksi permeabilitas pasif molekul terhadap membran lipid bilayer berdasarkan deskriptor fisikokimia dari representasi SMILES. Dataset yang digunakan adalah PAMPA_NCATS dengan target klasifikasi biner, yaitu low/moderate permeability dan high permeability. Dataset terdiri dari 2034 molekul tanpa missing value dan tanpa duplikasi SMILES, dengan distribusi kelas yang tidak seimbang, yaitu 295 data low/moderate permeability dan 1739 data high permeability. SMILES divalidasi dan dikonversi menjadi sembilan deskriptor molekuler menggunakan RDKit, kemudian digunakan sebagai input beberapa model klasifikasi. Hasil evaluasi menunjukkan bahwa Random Forest menjadi model terbaik berdasarkan prioritas Macro-F1, Balanced Accuracy, dan ROC-AUC, dengan nilai accuracy 0,8477, Macro-F1 0,5885, Balanced Accuracy 0,5731, dan ROC-AUC 0,7083. Feature importance menunjukkan bahwa LogP, TPSA, MolWt, dan HeavyAtomCount menjadi fitur paling berpengaruh. Secara biologis, hasil ini konsisten dengan konsep permeabilitas pasif lipid bilayer karena lipofilisitas, polaritas, dan ukuran molekul berperan penting dalam kemampuan molekul melewati membran.

Keywords; membrane permeability, lipid bilayer, SMILES, RDKit, machine learning, physicochemical descriptors

I. PENDAHULUAN

1.1 Konsep Biologi dan Latar Belakang Masalah

Membran plasma merupakan struktur biologis yang memisahkan lingkungan internal dan eksternal sel serta mengatur perpindahan molekul melalui sifat permeabilitas selektif. Struktur lipid bilayer menyebabkan tidak semua molekul dapat melewati membran dengan tingkat kemudahan yang sama [3], [5].

Permeabilitas molekul dipengaruhi oleh berbagai sifat fisikokimia, seperti lipofilisitas, polaritas, ukuran molekul, jumlah donor dan akseptor ikatan hidrogen, fleksibilitas, serta muatan. Molekul hidrofobik atau nonpolar umumnya lebih mudah melewati bagian hidrofobik membran dibandingkan molekul polar atau bermuatan.

Permasalahan yang muncul adalah permeabilitas molekul tidak mudah diperkirakan hanya dari struktur kimianya secara visual karena adanya kombinasi sifat yang saling memengaruhi. Oleh karena itu, diperlukan pendekatan komputasi untuk mengubah struktur molekul menjadi fitur

numerik dan mempelajari hubungannya dengan kelas permeabilitas.

Penelitian ini berfokus pada permeabilitas pasif melalui lipid bilayer karena dataset PAMPA_NCATS merepresentasikan sistem membran buatan dan tidak memodelkan mekanisme transporter protein, kanal ion, maupun transport aktif yang membutuhkan energi.

1.2 Metode Komputasi Terkait dan Tinjauan Pustaka

Dalam komputasi biologi dan kimia, hubungan antara struktur molekul dan sifat biologis dapat dianalisis menggunakan pendekatan Quantitative Structure-Activity Relationship (QSAR), yaitu metode yang menghubungkan struktur molekul dengan aktivitas atau sifat tertentu melalui fitur numerik [1]. Pada penelitian ini, sifat yang diprediksi adalah permeabilitas pasif molekul terhadap lipid bilayer.

Struktur molekul direpresentasikan dalam bentuk SMILES, yaitu representasi teks yang dapat dibaca perangkat lunak kimia komputasi. Karena SMILES tidak dapat langsung digunakan sebagai input machine learning, representasi tersebut dikonversi menjadi deskriptor fisikokimia menggunakan RDKit. Deskriptor yang digunakan meliputi MolWt, LogP, TPSA, HBD, HBA, RotatableBonds, HeavyAtomCount, RingCount, dan FormalCharge [2].

Model machine learning kemudian digunakan untuk mempelajari hubungan antara deskriptor dan label permeabilitas. Scikit-learn digunakan untuk model seperti Logistic Regression, Random Forest, dan Support Vector Machine [6], sedangkan XGBoost digunakan sebagai model boosting pembanding yang mampu menangkap hubungan non-linear antarfitur [7].

Dengan menggabungkan konsep biologi membran, deskriptor molekuler, dan machine learning, penelitian ini membangun pipeline komputasi untuk memprediksi sekaligus menginterpretasikan permeabilitas pasif molekul terhadap lipid bilayer.

1.3 Rumusan Pertanyaan Penelitian

Berdasarkan konsep biologi dan pendekatan komputasi, penelitian ini dirumuskan dalam beberapa pertanyaan berikut.

1. Fitur fisikokimia molekul apa yang paling berpengaruh terhadap prediksi permeabilitas pasif molekul terhadap membran lipid bilayer?
2. Algoritma machine learning mana yang memberikan performa terbaik dalam mengklasifikasikan permeabilitas molekul berdasarkan deskriptor fisikokimia?

3. Bagaimana hasil prediksi dan feature importance model dapat dijelaskan berdasarkan konsep biologis transport pasif pada membran plasma?
4. Bagaimana keterbatasan dataset, terutama ketidakseimbangan kelas, memengaruhi performa dan interpretasi model?

1.3 Tujuan dan Kontribusi

Penelitian ini bertujuan membangun pipeline machine learning untuk memprediksi permeabilitas molekul terhadap lipid bilayer berdasarkan deskriptor fisikokimia. Secara khusus, penelitian ini menyiapkan dataset berbasis SMILES, mengekstraksi fitur molekuler yang relevan, membandingkan performa beberapa algoritma klasifikasi, serta menginterpretasikan fitur penting berdasarkan konsep biologi membran.

Kontribusi penelitian ini adalah menghasilkan alur komputasi sederhana yang menghubungkan struktur molekul dengan prediksi permeabilitas membran. Pipeline yang dibangun dapat memproses SMILES, menghasilkan fitur fisikokimia, melatih dan mengevaluasi model klasifikasi, serta mengaitkan hasil prediksi dengan konsep permeabilitas pasif pada lipid bilayer. Selain itu, penelitian ini juga menunjukkan pentingnya pemilihan metrik evaluasi pada dataset dengan distribusi kelas yang tidak seimbang.

II. METODE

2.1 Dataset dan Komponen Data


Dataset yang digunakan adalah PAMPA_NCATS, yaitu dataset permeabilitas molekul berbasis struktur SMILES [4]. Dataset ini digunakan untuk klasifikasi biner, dengan label 0 merepresentasikan low/moderate permeability dan label 1 merepresentasikan high permeability. Dalam proyek ini, dataset disimpan secara lokal pada `data/raw/pampa_ncats_raw.csv` agar seluruh anggota kelompok menggunakan sumber data yang sama dan proses komputasi lebih mudah direproduksi.

Pada tahap data preparation, dataset dibaca menggunakan Python dan kolom distandarkan menjadi `Drug_ID`, `SMILES`, dan `Y`. Hasil pemeriksaan menunjukkan bahwa dataset terdiri dari 2034 molekul dan 3 kolom utama tanpa missing value. Seluruh SMILES juga bersifat unik, dengan distribusi kelas high permeability lebih dominan dibandingkan low/moderate permeability.

TABEL 1. RINGKASAN DATASET PAMPA_NCATS

Komponen	Keterangan
Jumlah data	2034 molekul
Jumlah kolom	3 kolom utama
Kolom utama	<code>Drug_ID</code> , <code>SMILES</code> , <code>Y</code>
SMILES unik	2034
Duplikasi SMILES	0
Missing value	0
Kelas 0	295 data, 14,5%

Komponen	Keterangan
Kelas 1	1739 data, 85,5%
Jenis masalah	Klasifikasi biner



Gambar 1. Distribusi Label Dataset PAMPA_NCATS

Gambar 1 menunjukkan bahwa kelas high permeability jauh lebih dominan dibandingkan kelas low/moderate permeability. Kondisi ini menunjukkan adanya class imbalance, sehingga evaluasi model tidak cukup hanya menggunakan accuracy.

2.2 Komponen Pipeline Komputasi

Pipeline komputasi dalam penelitian ini terdiri dari beberapa komponen yang saling terhubung. Setiap komponen memiliki fungsi tertentu, mulai dari pembacaan dataset, validasi struktur molekul, ekstraksi fitur, pelatihan model, evaluasi, hingga interpretasi hasil.

TABEL 2. KOMPONEN PIPELINE KOMPUTASI

Komponen	File/Output	Fungsi
Data preparation	<code>src/01_data_preparation.py</code>	Membaca dataset lokal, menstandarkan kolom, memeriksa missing value, duplikasi, dan distribusi label
Feature engineering	<code>src/02_feature_engineering.py</code>	Memvalidasi SMILES dan menghitung deskriptor fisikokimia menggunakan RDKit
Modeling dan evaluasi	<code>src/03_modeling.py</code>	Melatih beberapa model klasifikasi, mengevaluasi performa, memilih best model, menyimpan confusion matrix dan ROC curve
Interpretasi dan prediksi	<code>src/04_interpretation_and_prediction.py</code>	Menghitung feature importance dan memprediksi contoh SMILES baru
Dataset mentah	<code>data/raw/pampa_ncats_raw.csv</code>	Data awal berisi <code>Drug_ID</code> , <code>SMILES</code> , dan <code>Y</code>
Dataset fitur	<code>data/processed/pampa_features.csv</code>	Data hasil ekstraksi fitur molekuler
Output model	<code>models/best_model.pkl</code>	Model terbaik yang digunakan untuk prediksi
Output hasil	<code>results/tables</code> , <code>results/figures</code>	Tabel dan gambar hasil pengujian

Komponen ini menunjukkan bahwa penelitian tidak hanya menjalankan satu model, tetapi membangun pipeline komputasi lengkap yang dapat direproduksi dari data mentah hingga prediksi molekul baru.

2.3 Preprocessing dan Ekstraksi Fitur Molekuler

Preprocessing awal dilakukan dengan membaca dataset PAMPA_NCATS, memeriksa kelengkapan data, menstandarkan nama kolom, dan melihat distribusi label target. Tahap ini penting untuk memastikan bahwa data yang digunakan pada proses modeling memiliki format yang konsisten.

Karena input molekul berupa SMILES, validasi struktur molekul dilakukan menggunakan RDKit sebelum fitur dihitung. Pada proses validasi, seluruh 2034 SMILES dalam dataset dinyatakan valid, sehingga tidak ada data yang dihapus pada tahap feature engineering. Setelah validasi, molekul dikonversi menjadi sembilan deskriptor fisikokimia. Deskriptor ini dipilih karena berkaitan dengan faktor biologis yang memengaruhi permeabilitas pasif molekul terhadap lipid bilayer.

TABEL 3. DESKRIPTOR FISIKOKIMIA MOLEKULER

Fitur	Makna	Alasan
MolWt	Berat molekul	Molekul besar cenderung lebih sulit berdifusi
LogP	Lipofilisitas	Menggambarkan kemampuan berinteraksi dengan lipid
TPSA	Polar Surface Area	Menggambarkan polaritas permukaan molekul
HBD	Hydrogen bond donor	Meningkatkan karakter polar molekul
HBA	Hydrogen bond acceptor	Meningkatkan karakter polar molekul
RotatableBonds	Ikatan rotabel	Menggambarkan fleksibilitas struktur
HeavyAtomCount	Jumlah atom berat	Menggambarkan ukuran dan kompleksitas
RingCount	Jumlah cincin	Menggambarkan bentuk dan rigiditas molekul
FormalCharge	Muatan formal	Molekul bermuatan sulit berdifusi pasif

2.4 Model Machine Learning

Model machine learning yang digunakan dalam penelitian ini adalah beberapa model klasifikasi untuk memprediksi kelas permeabilitas molekul. Model yang dibandingkan meliputi Dummy Most Frequent sebagai baseline sederhana, Logistic Regression, Logistic Regression dengan `class_weight='balanced'`, Random Forest, Random Forest dengan `class_weight='balanced'`, Support Vector Machine, dan XGBoost.

Dummy Most Frequent digunakan untuk mengetahui performa dasar dari model yang selalu memprediksi kelas mayoritas. Hal ini penting karena dataset memiliki distribusi kelas yang tidak seimbang. Logistic Regression digunakan sebagai model linear sederhana. Random Forest digunakan karena sesuai untuk data tabular dan mampu menangkap hubungan non-linear antarfitur. Support Vector Machine digunakan sebagai pembanding non-linear, sedangkan

XGBoost digunakan sebagai model boosting yang umum digunakan untuk data tabular.

Data dibagi menjadi training set dan test set dengan rasio 80:20 menggunakan stratified split agar proporsi kelas tetap terjaga. Hasil pembagian data menghasilkan 1627 data training dan 407 data test. Pada test set, terdapat 59 data low/moderate permeability dan 348 data high permeability.


2.5 Evaluasi Model

Evaluasi model dilakukan pada test set hasil stratified split. Karena dataset memiliki distribusi kelas yang tidak seimbang, accuracy tidak digunakan sebagai satu-satunya dasar penilaian. Model yang sering memprediksi kelas mayoritas dapat memiliki accuracy tinggi, tetapi tetap gagal mengenali kelas low/moderate permeability.

Metrik yang digunakan meliputi accuracy, precision, recall, F1-score, Macro-F1, Balanced Accuracy, ROC-AUC, dan confusion matrix. Macro-F1 dan Balanced Accuracy digunakan untuk menilai performa secara lebih adil terhadap kedua kelas, ROC-AUC digunakan untuk melihat kemampuan pemisahan kelas, sedangkan confusion matrix digunakan untuk menganalisis pola kesalahan prediksi. Model terbaik dipilih dengan memprioritaskan Macro-F1, kemudian mempertimbangkan Balanced Accuracy dan ROC-AUC.

2.6 Flowchart dan Tautan Kode Program

Pipeline komputasi dalam penelitian ini dimulai dari pembacaan dataset PAMPA_NCATS yang disimpan secara lokal. Selanjutnya dilakukan pemeriksaan struktur data, missing value, duplikasi SMILES, dan distribusi label. SMILES kemudian divalidasi menggunakan RDKit. Molekul valid dikonversi menjadi deskriptor fisikokimia. Data fitur kemudian dibagi menjadi training set dan test set. Beberapa model klasifikasi dilatih pada training set, kemudian dievaluasi pada test set. Model terbaik digunakan untuk menghasilkan confusion matrix, ROC curve, feature importance, serta prediksi terhadap contoh SMILES baru.



Gambar 2. Flowchart Pipeline Komputasi

Tautan kode program:

<https://github.com/sonyaaputri/membrane-permeability-ml.git>

III. HASIL DAN DISKUSI

3.1 Statistik Dataset dan Deskriptor

Berdasarkan hasil data preparation, dataset PAMPA_NCATS terdiri dari 2034 molekul dengan tiga kolom utama, yaitu Drug_ID, SMILES, dan Y. Tidak ditemukan missing value pada kolom Drug_ID, SMILES, maupun Y.


Seluruh SMILES bersifat unik, sehingga tidak terdapat duplikasi struktur molekul pada dataset.

Distribusi label menunjukkan bahwa dataset tidak seimbang. Kelas low/moderate permeability berjumlah 295 data atau 14,5%, sedangkan kelas high permeability berjumlah 1739 data atau 85,5%. Ketidakseimbangan ini penting diperhatikan karena model dapat cenderung lebih sering memprediksi kelas mayoritas, yaitu high permeability.

TABEL 4. STATISTIK DESKRIPTOR MOLEKULER

Deskriptor	Mean	Min	Max	Std Dev
MolWt	397,6497	136,1140	974,6340	83,7451
LogP	3,8513	-2,1729	8,8332	1,3179
TPSA	77,2736	6,4800	236,8100	27,9165
HBD	1,4543	0,0000	8,0000	0,9739
HBA	4,8378	1,0000	15,0000	1,6671
RotatableBonds	4,8122	0,0000	21,0000	2,3612
HeavyAtomCount	27,9867	10,0000	65,0000	5,8736
RingCount	3,8147	0,0000	9,0000	0,9731
FormalCharge	0,0000	0,0000	0,0000	0,0000

Statistik deskriptor menunjukkan bahwa rata-rata berat molekul dalam dataset adalah 397,6497, dengan nilai minimum 136,1140 dan maksimum 974,6340. Rata-rata LogP adalah 3,8513, yang menunjukkan bahwa banyak molekul dalam dataset memiliki karakter cukup lipofilik. Rata-rata TPSA adalah 77,2736, yang menunjukkan adanya variasi polaritas permukaan molekul. Nilai FormalCharge bernilai 0 pada seluruh data, sehingga fitur ini tidak memberikan variasi pada dataset yang digunakan.



Gambar 3. Distribusi Deskriptor Molekuler

Gambar 3 memperlihatkan distribusi setiap deskriptor pada kelas high permeability dan low/moderate permeability.


Visualisasi ini menunjukkan bahwa fitur seperti LogP, TPSA, MolWt, HBD, dan HBA relevan untuk dianalisis karena berkaitan dengan lipofilisitas, polaritas, ukuran molekul, dan kemampuan membentuk ikatan hidrogen. Distribusi deskriptor juga memperlihatkan dominasi jumlah data kelas high permeability pada hampir seluruh subplot, sesuai dengan distribusi label dataset.

3.2 Perbandingan Performa Model (andri)

Beberapa model klasifikasi dilatih dan dibandingkan menggunakan test set, yaitu Dummy Most Frequent, Logistic Regression, Logistic Regression Balanced, Random Forest, Random Forest Balanced, Support Vector Machine, dan XGBoost. Karena dataset tidak seimbang, pemilihan model terbaik tidak hanya didasarkan pada accuracy, tetapi juga mempertimbangkan Macro-F1, Balanced Accuracy, recall per kelas, dan ROC-AUC.

TABEL 5. PERBANDINGAN PERFORMA MODEL


Model	Accura cy	Macro- F1	Balanc ed Accura cy	Recall Low/M oderate	Recall High	ROC-A UC
Random Forest	0,8477	0,5885	0,5731	0,1864	0,9598	0,7083
Random Forest Balanced	0,8452	0,5774	0,5646	0,1695	0,9598	0,7165
XGBoost	0,8575	0,5689	0,5577	0,1356	0,9799	0,7394
Logistic Regression Balanced	0,6511	0,5552	0,6482	0,6441	0,6523	0,7062
Logistic Regression	0,8624	0,5383	0,5395	0,0847	0,9943	0,7071
Support Vector Machine	0,8600	0,4949	0,5169	0,0339	1,0000	0,6822
Dummy Most Frequent	0,8550	0,4609	0,5000	0,0000	1,0000	0,5000



Gambar 4. Perbandingan Performa Model Klasifikasi

Berdasarkan Tabel 5 dan Gambar 4, Random Forest dipilih sebagai model terbaik karena memiliki Macro-F1 tertinggi, yaitu 0,5885, dengan ROC-AUC 0,7083. Walaupun Logistic Regression dan Dummy Most Frequent memiliki accuracy yang sedikit lebih tinggi, keduanya masih sangat dipengaruhi oleh dominasi kelas high permeability. Hal ini terlihat dari recall kelas low/moderate yang rendah, terutama pada Dummy Most Frequent yang bernilai 0,0000. Dengan demikian, accuracy saja tidak cukup untuk menilai model pada dataset yang tidak seimbang.


3.3 Analisis Confusion Matrix dan ROC Curve



Gambar 5. Confusion Matrix Model Random Forest

Berdasarkan confusion matrix, Random Forest berhasil memprediksi 334 data high permeability dengan benar, sedangkan 14 data high permeability salah diprediksi sebagai low/moderate. Pada kelas low/moderate permeability, model hanya mengenali 11 data dengan benar, sementara 48 data diprediksi sebagai high permeability. Hasil ini menunjukkan bahwa model masih lebih kuat mengenali kelas high permeability dibandingkan kelas low/moderate permeability.

Kecenderungan tersebut dipengaruhi oleh class imbalance, karena jumlah data high permeability jauh lebih dominan dalam dataset. Oleh karena itu, performa model perlu dianalisis menggunakan metrik tambahan seperti Macro-F1, Balanced Accuracy, recall per kelas, dan ROC-AUC, bukan accuracy saja.



Gambar 6. ROC Curve Model Random Forest


ROC Curve menghasilkan nilai AUC sebesar 0,7083. Nilai ini menunjukkan bahwa model memiliki kemampuan membedakan kelas low/moderate dan high permeability lebih baik dibandingkan random classifier, tetapi kemampuan pemisahan kelasnya masih belum sempurna.

3.4 Feature Importance dan Interpretasi Biologis

Feature importance digunakan untuk melihat fitur fisikokimia yang paling berpengaruh terhadap prediksi model Random Forest. Hasilnya menunjukkan bahwa fitur paling dominan adalah LogP, TPSA, MolWt, dan HeavyAtomCount.

TABEL 6. FEATURE IMPORTANCE MODEL RANDOM FOREST

Fitur	Raw Importance	Importance Ternormalisasi
MolWt	0,219706	1,000000
LogP	0,216646	0,986075
TPSA	0,186289	0,847900
HBD	0,097928	0,445725
HBA	0,082226	0,374256
RotatableBonds	0,077103	0,350936
HeavyAtomCount	0,072512	0,330039
RingCount	0,047590	0,216608
FormalCharge	0,000000	0,000000



Gambar 7. Feature Importance Model Random Forest

Secara biologis, hasil ini sesuai dengan konsep permeabilitas pasif lipid bilayer. LogP menggambarkan lipofilisitas molekul, sehingga fitur ini penting karena molekul yang lebih lipofilik cenderung lebih mudah berinteraksi dengan bagian hidrofobik membran. TPSA menggambarkan polaritas permukaan molekul; semakin tinggi TPSA, molekul cenderung semakin polar dan lebih sulit melewati inti hidrofobik lipid bilayer. MolWt dan HeavyAtomCount berkaitan dengan ukuran serta kompleksitas molekul, yang juga dapat memengaruhi kemampuan difusi pasif.

Fitur lain seperti HBD, HBA, RotatableBonds, dan RingCount tetap berkontribusi, tetapi tidak sebesar empat fitur utama tersebut. FormalCharge memiliki importance 0 karena pada dataset ini nilainya tidak bervariasi. Dengan demikian, model menangkap pola yang relevan secara biologis, yaitu bahwa permeabilitas pasif dipengaruhi oleh lipofilisitas, polaritas, dan ukuran molekul.

3.5 Prediksi Molekul Baru

Model Random Forest kemudian digunakan untuk memprediksi lima contoh molekul baru dari daftar SMILES yang sudah disiapkan pada script, yaitu Aspirin, Caffeine, Ibuprofen, Ethanol, dan Glucose. Setiap SMILES divalidasi menggunakan RDKit, dikonversi menjadi deskriptor fisikokimia, lalu dimasukkan ke model untuk memperoleh kelas prediksi dan probabilitas high permeability.

TABEL 7. PREDIKSI MOLEKUL BARU

Molekul	MolWt	LogP	TPSA	Prediksi	Prob. High
Aspirin	180,15	1,31	63,60	High Permeability	0,9700
Caffeine	194,19	-1,03	61,82	High Permeability	0,6350
Ibuprofen	206,28	3,07	37,30	High Permeability	0,7950
Ethanol	46,07	-0,00	20,23	High Permeability	0,5500
Glucose	180,16	-3,22	110,38	Low/Moderate Permeability	0,2525

Hasil prediksi menunjukkan bahwa empat molekul diprediksi sebagai high permeability, sedangkan Glucose diprediksi sebagai low/moderate permeability. Prediksi Glucose sesuai dengan konsep biologis karena memiliki TPSA tinggi dan LogP rendah, yang menunjukkan karakter sangat polar dan kurang lipofilik sehingga sulit melewati inti hidrofobik lipid bilayer secara pasif.

Sebaliknya, Ibuprofen memiliki LogP lebih tinggi dan TPSA lebih rendah, sehingga lebih sesuai dengan karakter molekul yang mudah berinteraksi dengan membran lipid. Ethanol diprediksi sebagai high permeability, tetapi probabilitasnya hanya 0,5500, sehingga hasil ini perlu diinterpretasikan secara hati-hati. Secara umum, demo ini menunjukkan bahwa pipeline dapat memproses contoh SMILES baru dan menghasilkan prediksi permeabilitas, meskipun hasilnya tetap perlu dipandang sebagai estimasi komputasional awal.

IV. KESIMPULAN

Penelitian ini berhasil membangun pipeline machine learning untuk memprediksi permeabilitas pasif molekul terhadap membran lipid bilayer berdasarkan deskriptor fisikokimia dari representasi SMILES. Dataset PAMPA_NCATS diproses dari file lokal, divalidasi menggunakan RDKit, kemudian dikonversi menjadi fitur numerik seperti MolWt, LogP, TPSA, HBD, HBA,

RotatableBonds, HeavyAtomCount, RingCount, dan FormalCharge.

Hasil evaluasi menunjukkan bahwa Random Forest menjadi model terbaik berdasarkan prioritas Macro-F1, Balanced Accuracy, dan ROC-AUC, dengan accuracy 0,8477 dan ROC-AUC 0,7083. Namun, confusion matrix menunjukkan bahwa model masih lebih kuat mengenali kelas high permeability dibandingkan low/moderate permeability akibat distribusi kelas yang tidak seimbang. Oleh karena itu, accuracy saja tidak cukup untuk menilai performa model.

Feature importance menunjukkan bahwa LogP, TPSA, MolWt, dan HeavyAtomCount merupakan fitur paling berpengaruh. Hasil ini sesuai dengan konsep permeabilitas pasif lipid bilayer, karena lipofilisitas, polaritas, dan ukuran molekul berperan penting dalam kemampuan molekul melewati membran. Kontribusi penelitian ini adalah menyediakan pipeline komputasi sederhana yang menghubungkan struktur molekul, model machine learning, dan interpretasi biologis. Penelitian selanjutnya dapat menggunakan dataset yang lebih seimbang, teknik resampling atau threshold tuning, serta validasi eksternal dengan dataset permeabilitas lain.

TAUTAN KODE PROGRAM DAN VIDEO

Kode program:

<https://github.com/sonyaaputri/membrane-permeability-ml.git>

Video demo:  K03_04_KDS26.mov

PPT: canva.link/K03-04-KDS26

DAFTAR PUSTAKA

- [1] A. Tropsha, "Best Practices for QSAR Model Development, Validation, and Exploitation," *Molecular Informatics*, vol. 29, no. 6–7, pp. 476–488, 2010.
- [2] G. Landrum, "RDKit: Open-source cheminformatics," 2006. [Online]. Available: <https://www.rdkit.org/>
- [3] B. Alberts et al., *Molecular Biology of the Cell*, 6th ed. New York: Garland Science, 2015.
- [4] National Center for Advancing Translational Sciences, "PAMPA_NCATS dataset," PubChem BioAssay / MoleculeNet dataset source.
- [5] N. A. Campbell et al., *Campbell Biology*, 12th ed. Pearson, 2020.
- [6] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [7] T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, pp. 785–794.